

Báo cáo hàng tuần

1. Tổng quan

Trong tuần này, nhóm tập trung vào việc xây dựng tập dữ liệu benchmark phục vụ phát hiện lỗi sai của học sinh so với lời giải mẫu dựa trên GSM8K. Mục tiêu chính là tạo ra một tập dữ liệu có kiểm soát, phục vụ cho việc đánh giá block evidence và phân tích lỗi của mô hình trong các bài toán suy luận toán học nhiều bước.

Link tập benchmark:

<https://docs.google.com/spreadsheets/d/15qdyOj1HBPLfwR3n8r9Tpcxn-aDvcOESdbxUjWPnAQg/edit?hl=vi&gid=1544433238#gid=1544433238>

2. Mô tả cấu trúc dữ liệu

Mỗi mẫu trong tập benchmark bao gồm các trường chính sau:

- **question**: Câu hỏi dạng bài toán đố.
- **official answer** : Đáp án cuối cùng chính xác.
- **official response** : Lời giải đúng, bao gồm các bước suy luận chi tiết.
- **student answer**: Lời giải sai được tạo có chủ đích.
- **wrong**: Nhãn sai (yes/no).
- **type**: Loại lỗi được gán thủ công (nếu là mẫu sai).
- **wrong location**: Vị trí bước bắt đầu sai

Cấu trúc này cho phép không chỉ đánh giá độ chính xác mà còn phân tích chi tiết hành vi sai của mô hình.

3. Phương pháp thu thập dữ liệu

3.1. Nguồn dữ liệu

Các bài toán được xây dựng dựa trên định dạng GSM8K, tập trung vào các bài toán yêu cầu suy luận nhiều bước với ngữ cảnh thực tế.

3.2. Quy trình tạo mẫu

Quy trình tạo dữ liệu được thiết kế theo hướng *kiểm soát lỗi có chủ đích*, gồm các bước:

- Thu thập hoặc xây dựng bài toán kèm lời giải đúng
- Xác minh đáp án và lời giải chuẩn
- Tạo lời giải sai bằng cách:
 - Sao chép lời giải đúng
 - Chỉnh sửa một hoặc nhiều bước để tạo lỗi
 - Giữ nguyên cấu trúc để đảm bảo lời giải vẫn “hợp lý” về mặt hình thức

3.3. Gán nhãn lỗi

Sau khi tạo lời giải sai, lỗi được gán nhãn thủ công dựa trên phần bị chỉnh sửa, bao gồm các nhóm như:

- Đúng hoàn toàn (all right): Nhãn khi bài giải học sinh đúng hoàn toàn so với bài giải chuẩn, nhãn này chỉ để test hệ thống và chiếm tỷ lệ thấp nhất. 3
- Trả lời bằng chữ (answer by word): Nhãn khi bài giải học sinh trả lời 1 phần hoặc toàn bộ bằng từ ngữ thay vì số, nhãn này dùng để test khả năng tách từ và số của hệ thống. 1
- Gộp bước (combine step): Nhãn khi bài giải học sinh gộp 1 hoặc nhiều bước so với lời giải chuẩn. 3
- Cách tính khác (different calculation): Nhãn khi bài giải học sinh tính toán theo cách khác so với lời giải chuẩn $3 + 4$
- Không đổi đơn vị (do not convert units): Nhãn khi bài giải học sinh không đổi đơn vị mà tính trực tiếp trên con số đề bài đưa (VD không đổi cm thành mm) $2 + 3$
- Bước thừa (extra step): Nhãn khi bài giải học sinh có 1 hoặc nhiều bước không liên quan đến mục tiêu tính toán 2

- Lỗi logic (logic error) : Nhãn khi bài giải học sinh thay số khó hiểu sau mỗi phép tính (giá trị sau khác giá trị vừa tính được) 2
- Đọc sai đề (misreading) : Nhãn khi bài giải học sinh dùng số liệu khác đề bài để tính toán 2
- Thiếu bước (missing steps) : Nhãn khi bài giải học sinh thiếu các bước trước đó liên quan đến phép tính hiện tại 2
- Chỉ trả lời đáp án (only final answer): Nhãn khi bài giải học sinh chỉ trả lời đáp án cuối cùng 2
- Đảo bước (reverse steps) : Nhãn khi bài giải học sinh đảo thứ tự các bước tương đương (bước có thể đảo mà không làm lời giải sai) 3
- Lỗi chính tả (spelling errors): Nhãn khi bài giải học sinh có lỗi chính tả ở các chủ thể, mục đích để xem hệ thống có nhận dạng ra đây là lỗi chính tả và không tạo ra 1 thực thể tính toán mới không 1
- Tách bước (step separation): Nhãn khi bài giải học sinh tách nhỏ các bước so với lời giải chuẩn 3
- Thiếu đơn vị (units missing): Nhãn khi bài giải học sinh không có đơn vị trong 1 hoặc nhiều bước trong lời giải 2
- Lỗi diễn đạt (word problem): Nhãn khi bài giải học sinh trả lời tối nghĩa, mục đích nhằm kiểm tra việc tạo thực thể của hệ thống khi bài giải tối nghĩa 1 + 4
- Tính toán sai (wrong calculation) : Nhãn khi bài giải học sinh có phép tính bị tính sai. 2
- Sai quan hệ (wrong relationship): Nhãn khi bài giải học sinh bị nhầm quan hệ giữa các thực thể dẫn đến sai dấu trong phép tính. 2 + 3
- Sai mục tiêu (wrong target): Nhãn khi bài làm học sinh bị sai mục tiêu tính toán 2
- Đổi đơn vị sai (wrong units conversion): Nhãn khi bài làm học sinh đổi đơn vị sai (VD 1 cm = 100 mm) 3

3.4. Đảm bảo chất lượng dữ liệu

- Lời giải đúng được kiểm tra kỹ để đảm bảo tính chính xác

- Lời giải sai chỉ chứa lỗi mục tiêu (hạn chế nhiều nhiều lỗi)
- Dữ liệu được chuẩn hóa về định dạng

Phương pháp này giúp tạo ra dataset có khả năng phân tích lỗi rõ ràng và có tính giải thích cao.

4. Chấm điểm

Nhóm dự kiến sẽ chấm điểm benchmark dựa trên nhãn. Mô hình nhận input là lời giải chuẩn và lời giải của học sinh sau đó dự đoán các nhãn (có thể 1 hoặc nhiều nhãn)

- Nhãn đúng được +1 điểm
- Nhãn sai bị -1 điểm

5. Thống kê kết quả

- Tổng số mẫu: **200**
- Số mẫu đúng: **67 (33.5%)**
- Số mẫu sai: **133 (66.5%)**

Phân bố lỗi chính:

Type	Number	Percent
all right	6	3
answer by word	11	5,5
combine steps	18	9
different calculation	21	10,5
do not convert units	5	2,5
extra step	11	5,5
logic error	20	10
misreading	20	10

missing steps	12	6
only final answer	5	2,5
reverse steps	10	5
spelling errors	11	5,5
step separation	11	5,5
unit missing	11	5,5
word problem	11	5,5
wrong caculation	36	18
wrong relationship	36	18
wrong target	13	6,5
wrong unit conversion	8	4

6. Phân tích

- Tỷ lệ lỗi cao (~66.5%) là do dataset được thiết kế có chủ đích để chứa lỗi
- Các lỗi phổ biến nhất liên quan đến:
 - Tính toán số học
 - Hiểu sai quan hệ giữa các đại lượng
 - Đọc sai đề
 - Lỗi logic
- Việc kiểm soát lỗi giúp dễ dàng phân tích điểm yếu cụ thể của mô hình

7. Khó khăn

- Việc tạo lỗi nhưng vẫn giữ lời giải “hợp lý” đòi hỏi chỉnh sửa cẩn thận
- Phân loại lỗi cần sự nhất quán để tránh chồng chéo giữa các loại
- Có những dạng lỗi đặc thù như tính theo cách khác (different calculation), đảo bước (reverse steps), gộp bước (combine steps), tách bước (step separation), đổi đơn vị sai (wrong unit conversion), không đổi đơn vị (do not convert units)

không phải bài nào cũng có nên phân bố các lỗi này không cao như lỗi khác. Ngoài ra các lỗi này là nguyên nhân chính khiến việc sinh lời giải bằng LLM bị hạn chế.

8. Kế hoạch cho tuần tiếp theo

- Mở rộng dataset với nhiều dạng lỗi phức tạp hơn
 - Đánh giá hệ thống nhóm phát triển và model base trên tập benchmark
-

9. Kết luận

Trong tuần này, nhóm đã xây dựng thành công tập benchmark gồm 200 mẫu với lỗi được kiểm soát và gán nhãn rõ ràng. Dataset này tạo nền tảng vững chắc cho việc phân tích sâu khả năng suy luận và xử lý lỗi của mô hình.